智能信号处理与机器学习基础

基础矩阵定义与运算

Review of Basics: Matrix Definitions and Operations

主讲：石栋元
西北工业大学航海学院

校训：公诚勇毅

本讲内容脉络

01 符号约定
02 向量范数与矩阵范数
03 线性方程组
04 奇异与条件数
05 特征分解
06 凸集

学习主线：范数（量长度）$\Longrightarrow$ 线性方程组（有无解、几个解、稳不稳）$\Longrightarrow$ 特征分解（变换的本质）$\Longrightarrow$ **凸集**（优化的地基）。

PART 01

符号约定

Notation



西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

符号表示：一看“肩章”就知道兵种

写法	示例	含义
普通斜体（不加粗）	x, X	标量——就是一个数
小写加粗斜体	$\boldsymbol{x}$	列向量（默认“竖着站”）
大写加粗正体	$\mathbf{X}$	矩阵
右上角 T	$\boldsymbol{x}^{\mathsf{T}}$, $\mathbf{X}^{\mathsf{T}}$	转置：行列互换

快问快答

一个 $\boldsymbol{x}$（小写加粗）、一个 X（斜体不加粗），分别是什么？

线索：加粗看“体格”（向量/矩阵 vs 标量），大小写看“级别”（向量 vs 矩阵），两条线索一起看。

PART 02

向量范数与矩阵范数

Vector and Matrix Norms

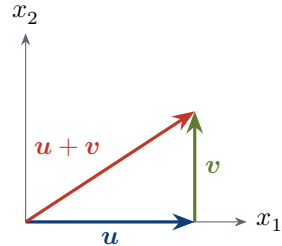


向量范数：给向量“量长度”的尺子

定义

向量空间上的范数 $\|\cdot\|$ 是一个**非负标量函数**，必须同时满足三条性质：

1. **三角不等式（次可加性）**
   $\|\boldsymbol{u}+\boldsymbol{v}\| \le \|\boldsymbol{u}\| + \|\boldsymbol{v}\|$
   两点之间直线最短，绕路只会更长
2. **齐次性**
   $\|a\boldsymbol{u}\| = |a|\ \|\boldsymbol{u}\|$
   向量放大 a 倍，长度放大 $|a|$ 倍
3. **非负性**
   $\|\boldsymbol{u}\| \ge 0$，且 $\|\boldsymbol{u}\| = 0 \iff \boldsymbol{u} = \boldsymbol{0}$
   长度为零的，只有零向量自己



直走（斜边）$\le$ 先走 $\boldsymbol{u}$ 再走 $\boldsymbol{v}$

向量范数（示例）：三把常用的尺子

- **欧几里得范数（2-范数）**：平方和开根号——“乌鸦飞行”的直线距离

$$\|\boldsymbol{x}\|_2 = \sqrt{x_1^2 + \cdots + x_n^2}$$

- **曼哈顿范数（1-范数）**：分量绝对值相加——方格街区里打车的路程

$$\|\boldsymbol{x}\|_1 = |x_1| + \cdots + |x_n|$$

- **p-范数（$p \geq 1$）**：把上面两把尺子统一起来

$$\|\boldsymbol{x}\|_p = \left(|x_1|^p + \cdots + |x_n|^p\right)^{1/p}$$

先留三个问题，想 30 秒（暂不翻页）

- $0 < p < 1$ 时，会出什么问题？
- $p \to \infty$ 时，p-范数变成什么？
- $p \to 0$ 时，又会怎样？

向量范数（示例）：边界问题揭晓

- $p \to \infty$：**= 无穷范数**

$$\|\boldsymbol{x}\|_\infty = \max_i |x_i|$$

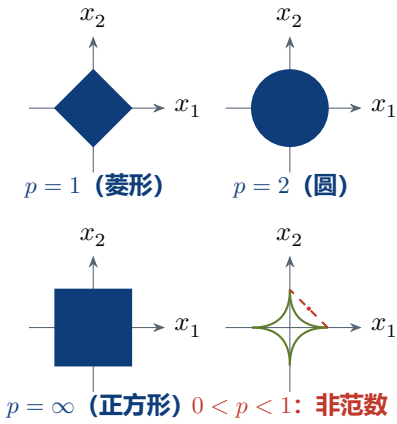
最大分量“一家独大”，如同比赛只记最好成绩

- $0 < p < 1$：**违反三角不等式（次可加性）**，不是范数
- $p \to 0$：**违反绝对齐次性**，也不是范数
- 工程上的“0-范数”：数向量中**非零元素的个数**

$$\|\boldsymbol{x}\|_0 = \#\{i : x_i \neq 0\}$$

压缩感知、稀疏表示天天和它打交道；1-范数是 0-范数最常用的**凸替身**，优化课还会回来。

(向量范数讲解)



矩阵范数：把矩阵看成空间里的一个“点”

定义

矩阵空间也是一个向量空间。矩阵范数同样是**非负标量函数**，三条规矩一字不差：

- 三角不等式：

$$\|\mathbf{A}+\mathbf{B}\| \le \|\mathbf{A}\| + \|\mathbf{B}\|$$

- 齐次性：

$$\|a\mathbf{A}\| = |a|\ \|\mathbf{A}\|$$

- 非负性：

$$\|\mathbf{A}\| \ge 0, \quad \|\mathbf{A}\| = 0 \iff \mathbf{A} = \mathbf{0}$$

思想上的一步

别把矩阵只当表格看——它是空间中的一个“点”，当然可以有长度。

但矩阵还代表一个**变换**，所以还会多出一种“诱导范数”。

矩阵范数（示例）：四把尺子

- **Frobenius 范数（F-范数）**：拉直成长向量按 2-范数量

$$\|\mathbf{A}\|_F = \left(\sum_{i=1}^{m} \sum_{j=1}^{n} |a_{ij}|^2 \right)^{1/2}$$

- **1-范数**：**列和取最大**

$$\|\mathbf{A}\|_1 = \max_{1 \le j \le n} \sum_{i=1}^{m} |a_{ij}|$$

- **2-范数（谱范数）**：最大奇异值

$$\|\mathbf{A}\|_2 = \sigma_{\max}(\mathbf{A})$$

- **诱导 p-范数**

$$\|\mathbf{A}\|_p = \sup_{\boldsymbol{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\boldsymbol{x}\|_p}{\|\boldsymbol{x}\|_p}$$

诱导范数的“人话”：放大器的最大增益——$\mathbf{A}\boldsymbol{x}$ 是 $\boldsymbol{x}$ 被矩阵作用后的结果，比值 $\frac{\|\mathbf{A}\boldsymbol{x}\|_p}{\|\boldsymbol{x}\|_p}$ 是“$\mathbf{A}$ 对这个方向的放大倍数”；对所有非零 $\boldsymbol{x}$ 取上确界，就是 $\mathbf{A}$ 能造成的**最大放大倍数（最大增益）**。

矩阵范数（续）：$\sigma_{\max}$ 怎么算，sup 与 max 之别

最大奇异值的算法

1. 构造 $\mathbf{A}^{\mathsf{T}}\mathbf{A}$；
2. 解特征方程

$$\det(\mathbf{A}^{\mathsf{T}}\mathbf{A} - \lambda\mathbf{I}) = 0;$$

3. 特征值开平方，取最大：

$$\sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^{\mathsf{T}}\mathbf{A})}.$$

$\mathbf{A}^{\mathsf{T}}\mathbf{A}$ 一定**对称半正定**，特征值必为非负实数，所以开方永远开得出来。

sup（上确界）vs max（最大值）

设 $S \subseteq \mathbb{R}$：

- 开区间 $(0, 1)$：能无限接近 1 但到不了——有上确界 1，没有最大值；
- 闭区间 $[0, 1]$：1 就在集合里——最大值就是 1。

类比：全年级成绩无限接近满分、但无人满分——“上限”存在，“状元”不存在。诱导范数写 sup 才严谨；**对矩阵而言这个上确界总能取到**，实际计算时当 max 用不出错。

课堂练习（例 1）：先自己动手

设 $\mathbf{A} = \begin{pmatrix} 1 & 2 \\ 2 & 1 \end{pmatrix}$

三个任务

1. 计算 F-范数 $\|\mathbf{A}\|_F$；
2. 计算 1-范数 $\|\mathbf{A}\|_1$；
3. 想一想 2-范数 $\|\mathbf{A}\|_2$ 的计算路子。

前两个现在动手，限时 2 分钟；2-范数待会儿一起算。

例 1 解答

- **F-范数**（别忘了最后开根号）：

$$\|\mathbf{A}\|_F = \left(1^2 + 2^2 + 2^2 + 1^2\right)^{1/2} = \sqrt{10} \approx 3.16$$

- **1-范数**（列和取最大）：

$$\|\mathbf{A}\|_1 = \max(|1| + |2|,\ |2| + |1|) = 3$$

- **2-范数**：$\mathbf{A}$ 对称，$\mathbf{A}^{\mathrm{T}}\mathbf{A} = \mathbf{A}^2$，直接求 $\mathbf{A}$ 的特征值：

$$\begin{vmatrix} 1-\lambda & 2 \\ 2 & 1-\lambda \end{vmatrix} = (1-\lambda)^2 - 4 = 0 \implies \lambda_1 = 3,\ \lambda_2 = -1$$

奇异值是特征值的绝对值，取最大：$\|\mathbf{A}\|_2 = 3$。

两个陷阱：特征值**可以为负**、奇异值永远非负，负特征值平方开方要取绝对值；　$\sqrt{10} \approx 3.16 > 3$ 不是巧合：$\|\mathbf{A}\|_F^2 = \sum_i \sigma_i^2$，恒有 $\|\mathbf{A}\|_2 \le \|\mathbf{A}\|_F$。

例 2：非对称矩阵，老老实实走 $\mathbf{A}^{\mathsf{T}}\mathbf{A}$

设 $\mathbf{A} = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix}$，则

$$\mathbf{A}^{\mathsf{T}}\mathbf{A} = \begin{pmatrix} 1 & 3 \\ -2 & 4 \end{pmatrix} \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix} = \begin{pmatrix} 10 & 10 \\ 10 & 20 \end{pmatrix}.$$

特征方程：

$$(10-\lambda)(20-\lambda) - 100 = 0 \implies \lambda = \frac{30 \pm \sqrt{500}}{2}.$$

$$\begin{aligned} \|\mathbf{A}\|_2 &= \sqrt{\tfrac{30+\sqrt{500}}{2}} \approx 5.12, \\ \|\mathbf{A}\|_F &= \sqrt{1+4+9+16} = \sqrt{30} \approx 5.48, \\ \|\mathbf{A}\|_1 &= \max(1+3,\ 2+4) = 6. \end{aligned}$$

三把尺子三个数

$$5.12 < 5.48 < 6$$

$$\|\mathbf{A}\|_2 < \|\mathbf{A}\|_F < \|\mathbf{A}\|_1$$

结论

不同范数量的是矩阵的**不同侧面**，用哪把尺子取决于要干什么——这正是机器学习里正则化选 L1 还是 L2 的底层逻辑。(矩阵范数讲解)

PART 03

线性方程组

Linear Equations





西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

线性方程组：写成矩阵形式

包含 m 个方程、n 个变量的线性方程组：

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = y_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = y_2 \\ \quad\cdots\cdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = y_m \end{cases}$$

令

$$\mathbf{A} = \begin{pmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{pmatrix}, \quad \boldsymbol{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, \quad \boldsymbol{y} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix},$$

则矩阵形式一行写完：

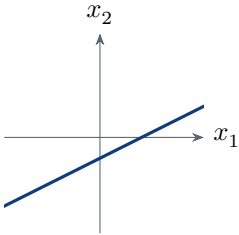
$$\mathbf{A}\boldsymbol{x} = \boldsymbol{y}$$

视角转换

“解方程”变成了“研究矩阵 $\mathbf{A}$ 的性质”：$\mathbf{A}$ 长什么样，决定了**有没有解、几个解、稳不稳。**

三种情形：挑一个 / 凑一个 / 不一定

欠定 $m < n$：解太多

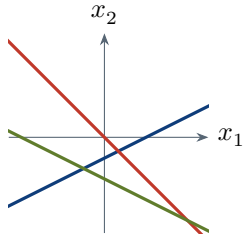


$x_1 - 2x_2 = 1$

一条直线：无穷多解

无穷多个里 → 挑一个

超定 $m > n$：没有严格解

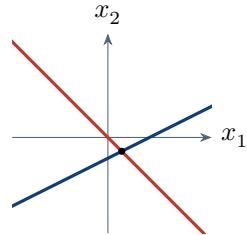


三条直线交不到一个点

严格解不存在

退一步 → 凑一个

确定 $m = n$：未必稳



两线交一点，看着挺美

但不一定总是可解、稳

先问 → 不一定

欠定：最小范数解（以 1-范数为标准）

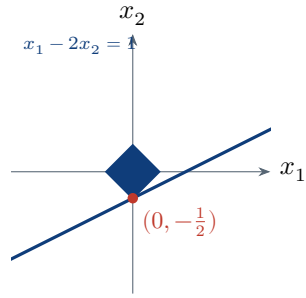
解集合是直线 $x_1 - 2x_2 = 1$，即 $x_2 = \dfrac{x_1 - 1}{2}$。

加一条“选美标准”：在所有解里挑范数最小的——

$$\min \ |x_1| + |x_2| = |x_1| + \left|\frac{x_1 - 1}{2}\right|.$$

对 x_1 分段讨论，最小值在 $x_1 = 0$ 取到：

$$x_1 = 0, \quad x_2 = -\frac{1}{2}$$



几何直觉：1-范数“单位球”是菱形，从小到大膨胀，**第一次碰到直线**的点即最小 1-范数解。

伏笔：尖角顶在坐标轴上 ⇒ 解常是**稀疏**的；压缩感知用 1-范数恢复稀疏信号正源于此。

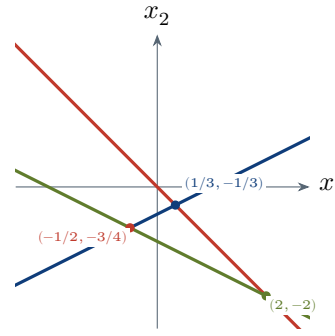
超定：三个裁判，打分不一致

三个方程、两个未知数：

$$x_1 - 2x_2 = 1, \quad x_1 + x_2 = 0, \quad 0.5x_1 + x_2 = -1.$$

两两组合，得到**三个互相打架的解**：

方程 (1)+(2)	方程 (2)+(3)	方程 (1)+(3)
$x_1 = 1/3$	$x_1 = 2$	$x_1 = -1/2$
$x_2 = -1/3$	$x_2 = -2$	$x_2 = -3/4$



没办法让三个方程同时严格成立——就像**没法让三个裁判都满意。**

超定的标准答案：最小二乘

退一步：不要求每个方程严格成立，只要求**总误差平方和最小**：

$$\min_{\boldsymbol{x}} \|\mathbf{A}\boldsymbol{x}-\boldsymbol{y}\|_2^2.$$

令导数为零，得到**正规方程**：

$$\mathbf{A}^{\mathsf{T}}\mathbf{A}\,\boldsymbol{x}=\mathbf{A}^{\mathsf{T}}\boldsymbol{y}.$$

代入本例：$\mathbf{A}^{\mathsf{T}}\mathbf{A}=\begin{pmatrix}9/4 & -1/2\\ -1/2 & 6\end{pmatrix}$，$\mathbf{A}^{\mathsf{T}}\boldsymbol{y}=\begin{pmatrix}1/2\\ -3\end{pmatrix}$，解得

$$\boldsymbol{x}^{*}=\left(\frac{6}{53},-\frac{26}{53}\right)\approx(0.11,-0.49)$$

若更信任某些方程（如信噪比高的传感器），给它更大权重——**加权最小二乘**。

为什么“平方”误差，不用绝对值？

1. **好求导**：平方处处可微，有闭式解（正规方程）；
2. **重罚大误差**：平方让偏差大的方程代价更高。

正规方程成立的前提

$\mathbf{A}^{\mathsf{T}}\mathbf{A}$ 可逆（列满秩）；病态时要加正则化——后面课程展开。

PART 04

奇异与条件数

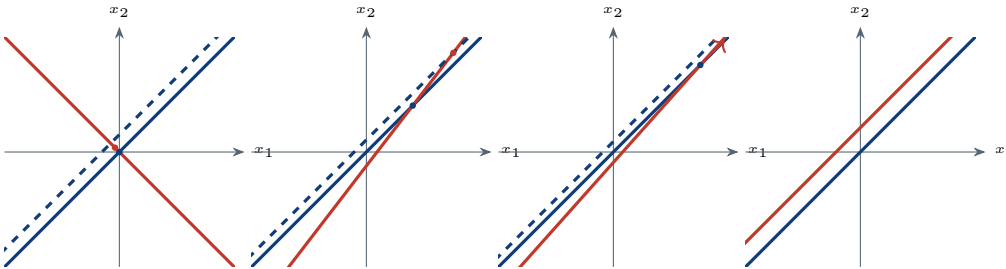
Singularity and Condition Number



西北工业大学

NORTHWESTERN POLYTECHNICAL UNIVERSITY

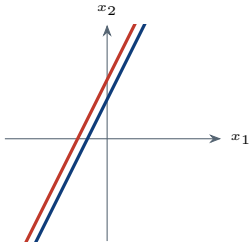
确定情形（续）：交点“一碰就跑”



夹角大：交点很“实” **近平行：交点变“虚”** **微扰一点，交点跑远** **完全平行：无解**

蓝线微微一挪（虚线），交点噌一下跑老远 $\Longrightarrow$ 反映在 $\mathbf{A}$ 上：**两行系数几乎成比例，行列式接近零**

推到极端：奇异矩阵与条件数



$$2x_1 - x_2 = -1$$
$$2x_1 - x_2 = -1.5$$

左边一模一样、右边不一样：矛盾，无解

完全平行时

$$\mathbf{A} = \begin{pmatrix} 2 & -1 \\ 2 & -1 \end{pmatrix}, \quad \det \mathbf{A} = 0, \quad \mathbf{A} \text{ 奇异}.$$

工程上更麻烦的是“几乎平行”：

$$\mathbf{A} = \begin{pmatrix} 2.00001 & -1 \\ 2 & -0.99999 \end{pmatrix},$$

$\det \mathbf{A}$ 不为零、却小得可怜：理论可解，右端项一丁点噪声，解就翻天覆地。(参考克拉默法则)

条件数（condition number）

度量矩阵“病态程度”的量；定义与计算后续课程展开。

信号处理含义：测量有噪声时解不可信；分布式定位中传感器布得太近（布站几何差）正是这个问题。

PART 05

特征分解

Eigen-Decomposition



西北工业大学

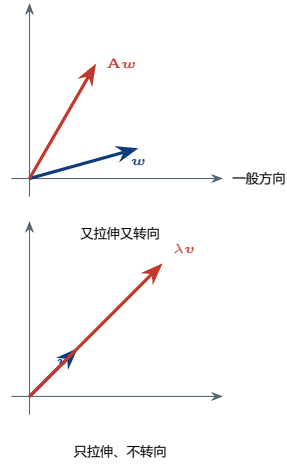
NORTHWESTERN POLYTECHNICAL UNIVERSITY

特征分解：只拉伸、不转向的方向

定义

n 阶方阵 $\mathbf{A}$，若**非零**向量 $\boldsymbol{v}$ 满足 $\mathbf{A}\boldsymbol{v} = \lambda\boldsymbol{v}$，则 $\boldsymbol{v}$ 是**特征向量**，标量 λ 是对应的**特征值**。

矩阵作用在一般向量上又旋转又拉伸；作用在**特征方向**上只拉伸、不转向，倍数就是 λ——像自动扶梯：只往前送，不把你甩到旁边。 (详细解释)



实对称矩阵的特征分解

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{\mathsf{T}}$$

$\mathbf{Q}$ 的列是**两两正交**的特征向量，$\mathbf{\Lambda}$ 为特征值对角阵；几何读法是**旋转—拉伸—转回**（$\mathbf{Q}^{\mathsf{T}}$ 换坐标系，$\mathbf{\Lambda}$ 沿轴拉伸，$\mathbf{Q}$ 转回）。

呼应前文： 例 1 解 $\det(\mathbf{A}^{\mathsf{T}}\mathbf{A} - \lambda\mathbf{I}) = 0$ 正是对 $\mathbf{A}^{\mathsf{T}}\mathbf{A}$ 做特征分解——奇异值即其特征值的平方根。(视频讲解)

PART 06

凸集

Convex Sets





西北工業大學
NORTHWESTERN POLYTECHNICAL UNIVERSITY

凸集：连接任意两点的线段整个还在集合里



凸集



非凸（连线出界）



凸集

写成式子：$\boldsymbol{x}_1, \boldsymbol{x}_2 \in \mathcal{C}$，对任意 $0 \le \theta \le 1$，

$$\theta \boldsymbol{x}_1 + (1-\theta)\boldsymbol{x}_2 \in \mathcal{C}.$$

θ 从 0 滑到 1，点就从 $\boldsymbol{x}_2$ 沿线段滑到 $\boldsymbol{x}_1$。

为什么关心凸?

凸集 + 凸函数 = 凸优化：局部最优就是全局最优，梯度下降才敢放心用。

本讲小结：地基到此打完

范数

- 三条性质
- $p \geq 1$ 才是范数
- F / 谱 / 1-范数
- 谱范数 $=$ 最大增益

方程组

- 欠定：最小范数解（稀疏）
- 超定：最小二乘
- 病态：条件数

特征分解

- $\mathbf{A}\boldsymbol{v} = \lambda \boldsymbol{v}$
- 对称阵 $\mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{\mathrm{T}}$
- 奇异值的来历

凸集

- 线段整个在内
- 凸优化：局部 $=$ 全局
- 梯度下降的地基

课后任务

1. **必做**：把例 2（$\mathbf{A} = \begin{pmatrix} 1 & -2 \\ 3 & 4 \end{pmatrix}$）的 F-范数、1-范数、2-范数**独立重算一遍**；
2. 用正规方程把超定例子（三方程两未知数）的最小二乘解重算一遍；
3. 预习第三章：凸函数与无约束优化。



谢　谢!

Questions & Discussion

西北工業大學
NORTHWESTERN POLYTECHNICAL UNIVERSITY